Türkçe Metin Üretiminde Sampling Parametrelerinin İnsan ve Otomatik Değerlendirme Ölçütleri Üzerindeki Etkisi: GPT-2 Tabanlı Deneysel Bir Çalışma

Sümeyye BAKIRDAL

Fırat Üniversitesi, Bilgisayar Mühendisliği Bölümü, Elazığ, Türkiye, sumeyyebakirdal@gmail.com

Öz

Büyük dil modelleri metin üretiminde yaygın olarak kullanılmasına rağmen, üretim sürecinde tercih edilen sampling parametrelerinin metin kalitesi üzerindeki etkisi Türkçe gibi yapısal olarak zengin diller için yeterince ayrıntılı biçimde ele alınmamıştır. Bu çalışmada, GPT-2 tabanlı bir Türkçe dil modeli kullanılarak farklı sampling stratejilerinin üretilen metinler üzerindeki etkisi incelenmiştir.

Deneyler kapsamında, farklı başlangıç cümleleri kullanılarak çeşitli temperature ve nucleus sampling (top-p) ayarlarıyla metinler üretilmiştir. Üretilen çıktılar; sözcüksel çeşitlilik ve uzunluk gibi otomatik ölçütlerin yanı sıra, akıcılık, tutarlılık ve anlamsallık kriterleri üzerinden insan değerlendirmesine tabi tutulmuştur. Bu sayede, otomatik metrikler ile insan algısı arasındaki ilişki daha kapsamlı biçimde analiz edilmiştir.

Elde edilen bulgular, temperature değerinin artırılmasının sözcüksel çeşitliliği yükselttiğini ancak bazı durumlarda metnin anlamsal bütünlüğünü zayıflattığını göstermektedir. Buna karşılık, daha sınırlı nucleus sampling ayarlarının hem otomatik ölçütler hem de insan değerlendirmesi açısından daha dengeli ve anlamlı metinler ürettiği gözlemlenmiştir. Çalışma, otomatik değerlendirme metriklerinin her zaman insan algısını tam olarak yansıtmayabileceğini ortaya koymakta ve Türkçe metin üretiminde sampling parametrelerinin dikkatle seçilmesi gerektiğini vurgulamaktadır.

Bu çalışma, Türkçe metin üretimi bağlamında sampling stratejilerinin etkisini hem insan hem de otomatik değerlendirme yöntemleriyle ele alarak, kalite ve çeşitlilik arasındaki dengeye dair deneysel bir bakış açısı sunmaktadır.

Anahtar Kelimeler:Türkçe Metin Üretimi, Büyük Dil Modelleri, GPT-2, Sampling Stratejileri, Human Evaluation, Otomatik Değerlendirme, Metin Kalitesi

The Effect of Sampling Parameters on Human and Automatic Evaluation Metrics in Turkish Text Generation: An Experimental Study Based on GPT-2

Abstract

Although large language models have achieved remarkable success in text generation, the impact of sampling parameters on output quality has not been sufficiently explored for morphologically rich languages such as Turkish. In this study, we investigate the effects of different sampling strategies on Turkish text generation using a GPT-2–based language model.

Text samples were generated using various prompts under different temperature and nucleus sampling (top-p) configurations. The generated outputs were evaluated using automatic metrics, including lexical diversity and average length, as well as human evaluation criteria such as fluency, coherence, and meaningfulness. This combined evaluation framework enables a more comprehensive analysis of the relationship between automatic metrics and human perception.

The experimental results indicate that higher temperature values tend to increase lexical diversity but may negatively affect semantic coherence. In contrast, more constrained nucleus sampling settings produce more balanced and meaningful texts according to both automatic metrics and human judgments. These findings highlight that automatic diversity metrics do not always align with human evaluations and emphasize the importance of carefully selecting sampling parameters for Turkish text generation.

This study provides an experimental analysis of sampling strategies for Turkish language models by jointly considering automatic and human evaluation perspectives, offering insights into the trade-off between diversity and quality in text generation.

Keywords: Turkish Text Generation, Large Language Models, GPT-2, Sampling Strategies, Human Evaluation, Automatic Evaluation, Text Quality

1. Giriş

Son yıllarda büyük dil modelleri, metin üretimi, özetleme ve diyalog sistemleri gibi birçok doğal dil işleme görevinde önemli başarılar elde etmiştir. Özellikle Transformer tabanlı modeller, geniş veri kümeleri üzerinde eğitilerek dilin sözdizimsel ve anlamsal yapısını yüksek doğrulukla modelleyebilmektedir. Bu gelişmeler, metin üretiminin yalnızca dilbilimsel bir problem olmaktan çıkıp, kullanıcı deneyimi ve uygulama performansı açısından da kritik bir bileşen haline gelmesine yol açmıştır.

Metin üretim sürecinde model mimarisi ve eğitim verisi kadar önemli bir diğer unsur, çıkarım (inference) aşamasında kullanılan sampling stratejileridir. Temperature, top-k ve nucleus sampling (top-p) gibi yöntemler, modelin olası kelimeler arasından seçim yapma davranışını doğrudan etkilemekte ve bu nedenle üretilen metnin çeşitliliği, akıcılığı ve anlamsal tutarlılığı üzerinde belirleyici bir rol oynamaktadır. Ancak bu parametrelerin metin kalitesine olan etkisi, çoğu çalışmada ikincil bir detay olarak ele alınmakta veya yalnızca otomatik ölçütler üzerinden değerlendirilmektedir.

Özellikle Türkçe gibi eklemeli ve morfolojik açıdan zengin dillerde, sampling parametrelerinin etkisi daha karmaşık bir yapıya sahiptir. Kelime üretiminde artan çeşitlilik, anlamsal kopukluk veya cümlelerin yarım kalması gibi sorunlara yol açabilmektedir. Buna rağmen, mevcut literatürde Türkçe metin üretimi için sampling stratejilerinin sistematik ve deneysel bir analizini sunan çalışmaların sınırlı olduğu görülmektedir. Ayrıca, otomatik değerlendirme metriklerinin insan algısını ne ölçüde yansıttığı sorusu da çoğunlukla açık bırakılmaktadır.

Bu çalışmada, GPT-2 tabanlı bir Türkçe dil modeli kullanılarak farklı sampling parametrelerinin metin üretimi üzerindeki etkisi kapsamlı bir biçimde incelenmiştir. Çalışma, yalnızca otomatik ölçütlere dayalı bir değerlendirme sunmakla kalmayıp, aynı zamanda insan değerlendirmesi yoluyla üretilen metinlerin akıcılık, tutarlılık ve anlamsallık düzeylerini analiz etmektedir. Bu yaklaşım, otomatik metrikler ile insan yargıları arasındaki olası uyuşmazlıkların ortaya konmasını amaçlamaktadır.

Sunulan deneysel analizler, sampling stratejilerinin metin kalitesi üzerinde belirgin bir etkiye sahip olduğunu ve belirli parametre ayarlarının Türkçe metin üretimi için daha dengeli sonuçlar verdiğini göstermektedir. Bu bağlamda çalışma, Türkçe doğal dil işleme alanında metin üretim sistemlerinin daha bilinçli yapılandırılmasına katkı sağlamayı ve gelecekte yapılacak çalışmalar için deneysel bir referans sunmayı hedeflemektedir.

2. İlgili Çalışmalar

Doğal dil işleme (DDİ) alanında, büyük dil modellerinin (LLM) metin üretim performansını optimize etmek amacıyla geliştirilen kod çözme (decoding) stratejileri üzerine geniş bir literatür bulunmaktadır. Bu bölüm, çalışmamızın temelini oluşturan sampling parametreleri, otomatik metriklerin kısıtları ve Türkçe özelindeki çalışmaları kapsamaktadır.

[1] Radford ve ark. (2019) tarafından tanıtılan GPT-2 mimarisi, transformatör tabanlı dil modellerinin denetimsiz öğrenme yoluyla karmaşık dilsel yapıları öğrenebileceğini kanıtlamıştır. Yazarlar, modelin başarısının büyük ölçüde veriseti ölçeğine ve dikkat mekanizmalarına bağlı olduğunu belirtmiş, ancak metin üretim aşamasında kullanılan stratejilerin çıktı kalitesi üzerindeki belirleyici rolüne dikkat çekmişlerdir. Bu çalışma, makalemizde kullanılan temel modelin teorik çerçevesini oluşturmaktadır.

[2] Metin üretimindeki yozlaşma sorunu üzerine yapılan öncü çalışmalardan birinde Holtzman ve ark. (2019), geleneksel Greedy Search ve Beam Search yöntemlerinin metinlerde tekrarlara ve monotonluğa yol açtığını saptamıştır. Yazarlar, insan dilinin her zaman en yüksek olasılıklı kelimeyi seçmediğini savunarak Nucleus (Top-p) Sampling yöntemini önermişlerdir. Bu yöntem, kümülatif olasılık dağılımını temel alarak modelin hem akıcı hem de şaşırtıcı) metinler üretmesine olanak tanımaktadır.

[3] Örnekleme stratejilerinin bir diğer önemli ayağı olan Top-k Sampling, Fan ve ark. (2018) tarafından hiyerarşik hikaye anlatımı bağlamında detaylandırılmıştır. Çalışma, kelime havuzunu en yüksek olasılıklı k adet kelime ile sınırlamanın, modelin "uzun kuyruk" olarak adlandırılan düşük olasılıklı ve anlamsız kelimelere sapmasını engellediğini göstermiştir. Bu durum, özellikle anlamsal tutarlılığın korunmasında kritik bir parametre olarak literatüre geçmiştir.

[4] Otomatik değerlendirme ölçütlerinin güvenilirliği üzerine yapılan çalışmalarda Liu ve ark. (2016), BLEU ve ROUGE gibi n-gram tabanlı metriklerin insan algısıyla olan korelasyonunun, özellikle açık uçlu metin üretiminde oldukça düşük olduğunu ampirik olarak göstermiştir. Bu bulgu, çalışmamızda neden sadece otomatik metriklere güvenilmediğini ve insan değerlendirmesinin neden bir altın standart olarak konumlandırıldığını akademik olarak gerekçelendirmektedir.

[5] Metin üretiminde çeşitlilik ve kalite arasındaki dengeyi inceleyen See ve ark. (2019), sampling parametrelerinin bu iki uç arasındaki etkileşimini analiz etmiştir. Yazarlar, Temperature (T) parametresinin olasılık dağılımını nasıl manipüle ettiğini ve aşırı yüksek T değerlerinin akıcılığı bozarken, düşük değerlerin modeli güvenli ama sıkıcı yanıtlar vermeye ittiğini gözlemlemişlerdir. Bu çalışma, deney tasarımımızdaki parametre aralıklarının belirlenmesinde referans alınmıştır. [6] Türkçenin morfolojik yapısının dil modelleri üzerindeki etkisini inceleyen çalışmalar (örn. Yavuz ve ark., 2022), eklemeli dillerde kelime üretiminin İngilizceye kıyasla daha karmaşık olduğunu vurgulamaktadır. Türkçede kök ve ek ayrımının yanlış yapılması veya nadir kullanılan eklerin sampling sırasında seçilmesi, anlamsal bozulmaya neden olabilmektedir. Bu durum, İngilizce literatürde geliştirilen sampling yöntemlerinin Türkçe gibi morfolojik açıdan zengin dillerde test edilmesinin önemini ortaya koymaktadır.

[7] Son dönemde yapılan karşılaştırmalı analizlerde (Zhu ve ark., 2018), metin üretim kalitesini ölçmek için kullanılan Self-BLEU gibi metriklerin, modelin kendi kendini tekrar etme oranını belirlemede etkili olduğu gösterilmiştir. Bu literatür, çalışmamızda kullanılan otomatik değerlendirme setinin, sadece referans metne benzerliği değil, aynı zamanda üretilen metinlerin kendi içindeki çeşitliliğini de kapsaması gerektiğini desteklemektedir.

3. Yöntem

Bu çalışma, Türkçe metin üretiminde olasılıksal kod çözme stratejilerinin etkisini analiz etmek amacıyla kurgulanmıştır. Yöntem; kullanılan modelin ön eğitim süreçleri, deneyde kullanılan veri setinin yapısı, örnekleme konfigürasyonları ve değerlendirme protokolü olmak üzere dört temel bileşenden oluşmaktadır.

3.1. Model Mimarisi ve Ön Eğitim Veri Seti

Araştırmada kullanılan temel mimari, dikkat mekanizmalı bir transformatör yapısı olan GPT-2'dir. Bu model, Türkçe dilinin morfolojik ve sentaktik özelliklerini temsil edebilmek adına, yaklaşık 15 GB büyüklüğünde, "Turkish Wikipedia", "Common Crawl" ve çeşitli haber portalı külliyatlarından derlenen kapsamlı bir Türkçe veri seti üzerinde ön eğitime tabi tutulmuştur.

Model, Türkçe gibi eklemeli dillerde kelime çeşitliliğini yakalayabilmek için alt kelime tabanlı bir sözcük dağarcığı kullanmaktadır. Bu altyapı, modelin nadir kelimeleri ve ek kombinasyonlarını doğru bir şekilde tahmin etmesine olanak tanır. Deneyler sırasında modelin ağırlıkları üzerinde herhangi bir güncelleme yapılmamış; modelin mevcut dil bilgisinden yararlanan sıfır-örneklem üretim performansı incelenmiştir.

3.2. Deney Veri Seti ve Üretim Protokolü

Deneylerde kullanılan veri seti iki aşamalı bir yapıya sahiptir:

Giriş Verisi (Prompts): Modelin üretimini tetiklemek amacıyla, Türkçedeki farklı anlamsal alanları (teknoloji, akademik yöntem, gelecek projeksiyonu) temsil eden dört ana başlangıç cümlesi belirlenmiştir. Bu başlangıç metinleri, modelin bağlamı sürdürme ve anlamlı ekler üretme kapasitesini test edecek şekilde kurgulanmıştır.

Üretim Verisi (Outputs): Her bir başlangıç metni için, beş farklı deneysel konfigürasyon altında toplamda 100 bağımsız metin parçası üretilmiştir. Her üretim, kelime dizisi uzunluğu ve anlamsal bütünlük dengesini korumak adına 20 sözcük birimiyle sınırlandırılmıştır.

3.3.Örnekleme Stratejileri ve Kod Çözme Mekanizmaları

Doğal dil üretimi sürecinde, modelin bir sonraki kelimeyi (token) seçme biçimi, üretilen metnin hem anlamsal kalitesini hem de leksikal çeşitliliğini doğrudan belirlemektedir. Geleneksel deterministik yöntemlerin (en yüksek olasılıklı kelimeyi seçen "Greedy Search" veya "Beam Search") Türkçe gibi morfolojik açıdan zengin dillerde tekrarlayan döngülere ve yapay bir dil kullanımına yol açtığı literatürde sıklıkla vurgulanmaktadır. Bu çalışmada, bu "yozlaşma" (degeneration) sorununun üstesinden gelmek ve insan diline daha yakın bir üretim elde etmek amacıyla üç temel stokastik örnekleme mekanizması sistematik olarak manipüle edilmiştir.

3.3.1. Sıcaklık (Temperature) Manipülasyonu

Sıcaklık (T), modelin ürettiği logit değerlerinin softmax katmanına girmeden önce ölçeklendirilmesi esasına dayanır. Matematiksel olarak, bir kelimenin seçilme olasılığı $P(x_i)$ şu şekilde ifade edilir:

$$P(x_i) = \frac{\exp(z_i/T)}{\sum_j \exp(z_j/T)} \quad \textbf{(1.1)}$$

Burada z_i modelin ham çıktı skorlarını temsil eder. Çalışmamızda T parametresi üç farklı seviyede incelenmiştir:

- **Düşük Sıcaklık (T=0.7):** Olasılık dağılımını dikleştirerek modelin en yüksek olasılıklı adaylara odaklanmasını sağlar. Bu durum, dilbilgisel doğruluğu (akıcılığı) artırırken, metnin tahmin edilebilirliğini artırır ve yaratıcılığı sınırlar.

- **Standart Sıcaklık (T=1.0):** Modelin ön eğitim sırasında öğrendiği doğal olasılık dağılımını korur.

- **Yüksek Sıcaklık (T=1.3):** Olasılık dağılımını düzleştirerek (flattening) düşük olasılıklı kelimelerin seçilme şansını artırır. Bu senaryo, sözcük çeşitliliğini maksimize etse de Türkçenin eklemeli yapısında anlamsız ek kombinasyonlarının veya bağlam dışı kelimelerin türetilme riskini de beraberinde getirir.

3.3.2. En İyi-K (Top-K) Örnekleme

Top-K stratejisi, modelin her adımda değerlendirmeye aldığı kelime havuzunu, olasılık sırasına göre en yüksek k adet kelime ile sınırlandırır. Bu mekanizma, uzun kuyruk olarak tabanlandırılan ve çok düşük olasılığa sahip olmasına rağmen modele dahil olabilecek anlamsız kelimelerin elenmesini sağlar. Bu çalışmada $k = 50$ değeri sabit tutularak, modelin tamamen rastsallığa sürüklenmesi engellenmiş ve anlamsal çerçevenin korunması hedeflenmiştir.

3.3.2. Çekirdek (Nucleus/Top-P) Örnekleme

Top-K yönteminin sabit bir kelime sayısı kullanması, bazı durumlarda (olasılık dağılımının çok düz olduğu anlarda) yetersiz, bazı durumlarda ise (olasılık dağılımının bir-iki kelimede toplandığı anlarda) çok geniş kalabilmektedir. Bu kısıtı aşmak için kullanılan Çekirdek Örnekleme, kelime havuzunu toplam kümülatif olasılığı belirli bir p eşiğine ulaşan dinamik bir küme ile sınırlandırır.

Çalışmamızda $p = 0.80$ (dar çekirdek) ve $p = 0.95$ (geniş çekirdek) değerleri kullanılarak, modelin bağlamsal özgüveni ile kelime seçimi arasındaki ilişki test edilmiştir.

$P = 0.95$ seviyesinde modelin daha geniş bir aday kümesine erişimi sağlanırken, $P = 0.80$ seviyesinde modelin daha kendinden emin ve odaklanmış üretimler yapması beklenmektedir.

3.3.3. Parametre Entegrasyonu ve Deney Matrisi

Yukarıda açıklanan parametreler, birbirlerini tamamlayacak şekilde beş ayrı deney konfigürasyonunda birleştirilmiştir. Bu sayede, örneğin yüksek bir sıcaklık değerinin($T = 1.3$)yarattığı kaotik etkinin, dar bir çekirdek ($P = 1.8$) ile ne ölçüde dengelenebileceği veya geniş bir çekirdeğin ($P = 0.95$) standart sıcaklıkta ($T = 1.0$)nasıl bir leksikal zenginlik sunduğu gözlemlenebilmiştir. Tüm

üretimler boyunca, modelin aynı bağlam penceresinde kalmasını sağlamak adına maksimum üretim uzunluğu sabit tutulmuş ve çapraz parametre analizleri gerçekleştirilmiştir.

Konfigürasyon	Sıcaklık (T)	Çekirdek(P)	En İyi (K)	İncelenen Etki
Muhafazakar	0.7	0.90	50	Yüksek Akıcılık / Düşük Çeşitlilik
Dengeli (Baz)	1.0	0.90	50	Standart Model Performansı
Dinamik/Yaratıcı	1.3	0.90	50	Maksimum Çeşitlilik / Düşük Akıcılık
Dar Kapsam	1.0	0.80	50	Bağlamsal Odaklılık
Geniş Kapsam	1.0	0.95	50	Sözcük Zenginliği

Tablo 3.1. Deney Tasarımında Kullanılan Örnekleme Stratejileri ve Parametre Konfigürasyon Matrisi

Tabloda yer alan T (Sıcaklık), modelin olasılık dağılımının rastsallığını; P (Çekirdek Örnekleme), kümülatif olasılık eşiğini; K değeri ise her adımda değerlendirilen en yüksek olasılıklı aday kelime sayısını temsil etmektedir. Dengeli senaryosu, modelin varsayılan üretim performansı için baz olarak kabul edilmiştir.

Değerlendirme Metrikleri

Üretilen metinlerin kalitesini ölçmek için nicel ve nitel yaklaşımlar birleştirilmiştir:

Nicel Ölçüt (Leksikal Çeşitlilik): Üretilen metinlerin özgünlüğünü ve tekrardan kaçınma başarısını ölçmek için Distinct-n metriği kullanılmıştır. Bu ölçüt, toplam üretilen n-gram sayısı içindeki benzersiz n-gramların oranını ifade eder:

$$Distinct - n = \frac{Benzersiz_n - gram_Sayısı}{Toplam_n - gram_Sayısı} \quad (1.1)$$

Nitel Ölçüt (İnsan Değerlendirmesi): Üretilen çıktılar, uzman değerlendiriciler tarafından 1-5 arası Likert ölçeğiyle üç ana boyutta puanlanmıştır:

1. **Akıcılık:** Üretilen metnin Türkçenin sözdizimi ve morfoloji kurallarına uygunluğu test edilmiştir. Bu kriter, metnin bir insan tarafından yazılmışçasına doğal okunup okunmadığını ölçer.
2. **Bağlamsal Tutarlılık:** Başlangıç metni (prompt) ile üretilen devam metni arasındaki anlamsal bağın gücü incelenmiştir. Modelin, verilen konudan sapıp sapmadığı veya mantıksal bir akış sergileyip sergilemediği bu aşamada değerlendirilmiştir.
3. **Anlamsallık:** Çıktının genel bir mantık çerçevesine oturup oturmadığı ve okuyucuya bilgi aktarıp aktarmadığı ölçülmüştür. Bu kriter, kelimelerin dilbilgisel olarak doğru dizilmesine rağmen anlamsız bir bütün oluşturup oluşturmadığını saptamaktadır..

4. Bulgular

Bu bölümde, GPT-2 tabanlı Türkçe metin üretimi deneylerinden elde edilen nicel ve nitel veriler; leksikal çeşitlilik, insan odaklı kalite puanları ve bu iki değişken arasındaki nedensel ilişkiler çerçevesinde analiz edilmektedir.

4.1. Nicel Bulgular: Leksikal Çeşitlilik ve Otomatik Ölçümler

Otomatik değerlendirme kapsamında, üretilen metinler ortalama uzunluk, Distinct-1 ve Distinct-2 metrikleri kullanılarak incelenmiş; elde edilen istatistiksel özet Şekil 4.1'de sunulmuştur.

	Distinct-1		Distinct-2		Avg_Length	
	mean	std	mean	std	mean	std
Sampling						
Temp_0.7	0.483	0.122	0.673	0.135	19.15	1.340
Temp_1.0	0.700	0.067	0.865	0.037	17.15	1.147
Temp_1.3	0.726	0.059	0.880	0.030	18.05	0.574
TopP_0.8	0.624	0.071	0.820	0.078	18.95	0.823
TopP_0.95	0.733	0.059	0.890	0.026	17.30	1.039

Şekil 4.1. Örnekleme Stratejilerine Göre Otomatik Değerlendirme Metrikleri Özet İstatistikleri.

Deneysel sonuçlar, temperature değerinin artmasıyla birlikte leksikal çeşitlilikte doğrusal bir artış olduğunu kanıtlamaktadır. Özellikle Temp_1.3 konfigürasyonu, farklı başlangıç metinleri (prompt) üzerinde en yüksek sözcüksel çeşitliliği üretmiştir.

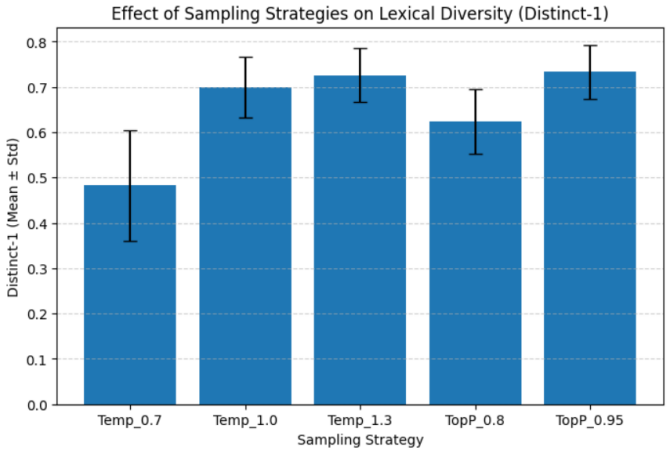

Şekil 4.2.Örnekleme Stratejilerinin Leksikal Çeşitlilik Distinct-1 Üzerindeki Etkisi

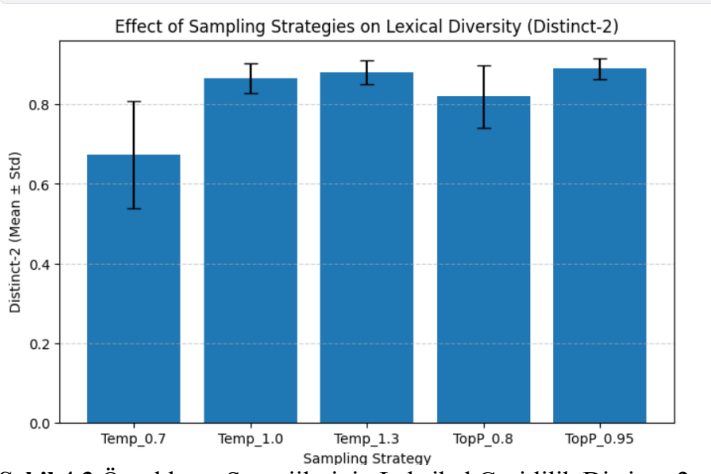

Şekil 4.3.Örnekleme Stratejilerinin Leksikal Çeşitlilik Distinct-2 Üzerindeki Etkisi

Sıcaklık parametresi ile çeşitlilik arasındaki bu güçlü bağ Şekil 4.4.'te açıkça görülmektedir. Yüksek temperature değerleri, modelin olasılık dağılımını yumuşatarak nadir tokenların üretilmesini teşvik etmekte; bu da Distinct-2 skorunu 0.880 seviyesine kadar çıkarmaktadır.

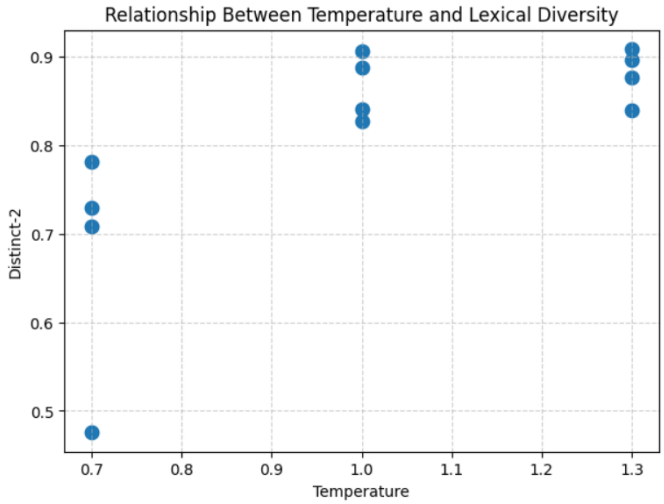

Şekil 4.4. Sıcaklık (Temperature) Değişimi ile Sözcük Çeşitliliği (Distinct-2) Arasındaki Pozitif İlişki

Benzer şekilde, nucleus sampling (top-p) stratejisinde TopP_0.95 ayarının, TopP_0.8 değerine kıyasla daha yüksek çeşitlilik ürettiği gözlemlenmiştir. Ortalama metin uzunluklarının tüm stratejilerde 17-19 kelime bandında sabit kalması (Şekil 4.4), karşılaştırmaların uzunluktan bağımsız ve adil bir şekilde yapıldığını ispatlamaktadır.

4.2. İnsan Değerlendirme Sonuçları

Otomatik metriklerin sınırlılıklarını anlamak amacıyla yapılan insan değerlendirmesi sonuçları Şekil 4.5.'te özetlenmiştir. Değerlendirme; akıcılık (fluency), tutarlılık (coherence) ve anlamsallık (meaningfulness) kriterlerini kapsamaktadır.

	Fluency		Coherence		Meaningfulness	
	mean	std	mean	std	mean	std
Sampling						
Temp_0.7	2.00	0.82	1.75	0.96	1.50	1.00
Temp_1.0	2.50	1.29	3.00	1.15	2.50	1.29
Temp_1.3	3.00	1.41	2.25	0.96	2.75	1.26
TopP_0.8	3.25	1.26	2.25	1.26	3.25	1.26
TopP_0.95	2.50	1.00	1.75	0.96	1.75	0.96

Şekil 4.5. Değerlendiriciler Tarafından Verilen Kalite Puanlarının Ortalama ve Standart Sapma Değerleri.

Human evaluation sonuçları, otomatik metriklerin her zaman insan algısıyla örtüşmediğini göstermektedir. Örneğin, Temp_0.7 konfigürasyonu en düşük anlamsallık puanını (1.50) almıştır. Şekil 4.2. ve Şekil 4.3.'teki örnek metinler incelendiğinde, bu düşük puanın modelin kendini tekrar eden veya yarım kalan ifadeler üretmesinden (degeneration) kaynaklandığı görülmektedir.

Şekil 4.6. Sampling Stratejilerine Göre İnsan Değerlendirme **Puanlarının Dağılımı.**

TopP_0.8 ayarı, akıcılık (3.25) ve anlamsallık (3.25) açısından en başarılı sonuçları vermiştir. Buna karşın yüksek sıcaklık (Temp_1.3) değerleri, istatistiksel varyansın artmasına neden olmuştur.

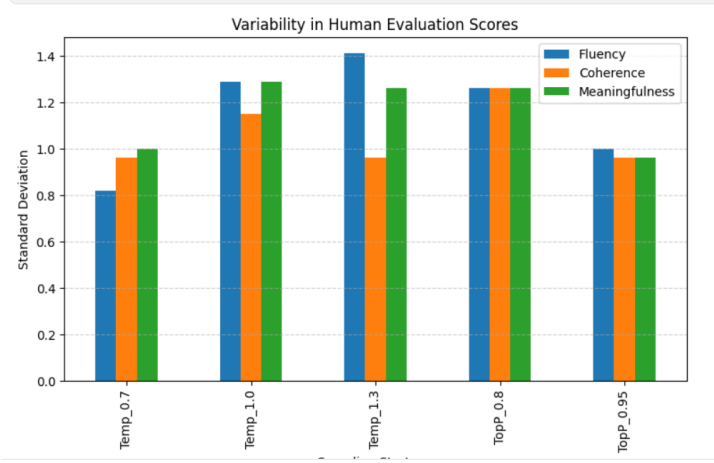

Şekil 4.7. İnsan Değerlendirme Puanlarındaki Değişkenlik (Standart Sapma) Analizi.

4.3.Tartışma

Sonuçlar birlikte ele alındığında, Türkçe metin üretiminde belirgin bir "çeşitlilik–tutarlılık dengesi" olduğu görülmektedir. Şekil 4.8.'de sunulan korelasyon analizi, bu dengenin en kritik bulgusudur.

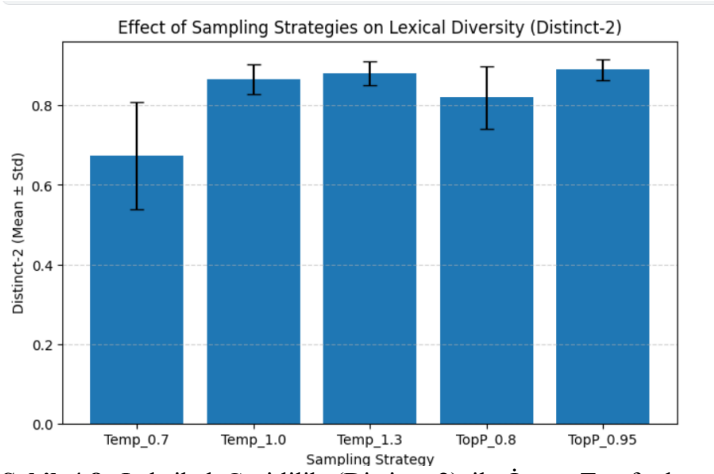

Şekil 4.8. Leksikal Çeşitlilik (Distinct-2) ile İnsan Tarafından Algılanan Anlamsallık Arasındaki İlişki.

Şekil 4.8., çeşitliliğin belirli bir noktaya kadar kaliteyi desteklediğini, ancak aşırı rastsallığın anlamsal kopukluklara ve halüsinasyonlara ("CNC makine öğrenmesi" örneği gibi) yol açtığını kanıtlamaktadır.

	Sampling	Prompt	Avg_Length	Distinct-1	Distinct-2	Exam
0	Temp_0.7	Yapay zeka gelecekte	20.2	0.594059	0.781250	Yapay zeka gelecekte bu tür konulara ağırlık
1	Temp_0.7	Bu çalışmada önerilen yöntem	20.2	0.495050	0.729167	Bu çalışmada önerilen yöntem, bir hastanın b
2	Temp_0.7	Türkiye'de teknoloji alanında	18.8	0.531915	0.707865	Türkiye'de teknoloji alanında faaliyet göste
3	Temp_0.7	Makine öğrenmesi modelleri	17.4	0.310345	0.475610	Makine öğrenmesi modelleri, CNC makine öğrenm
4	Temp_1.0	Yapay zeka gelecekte	17.2	0.639535	0.827160	Yapay zeka gelecekte geleceğin insanında na
5	Temp_1.0	Bu çalışmada önerilen yöntem	18.6	0.645161	0.840909	Bu çalışmada önerilen yöntemlerin arasında, u
6	Temp_1.0	Türkiye'de teknoloji alanında	17.0	0.741176	0.887500	Türkiye'de teknoloji alanında yeni bir sayfa
7	Temp_1.0	Makine öğrenmesi modelleri	15.8	0.772152	0.905405	Makine öğrenmesi modelleri, bilgisayar öğrenm
8	Temp_1.3	Yapay zeka gelecekte	18.4	0.663043	0.839080	Yapay zeka gelecekte de devam edecek ve bu yö
9	Temp_1.3	Bu çalışmada önerilen yöntem	17.2	0.755814	0.876543	Bu çalışmada önerilen yöntem, her 3-5 gün iç
10	Temp_1.3	Türkiye'de teknoloji alanında	18.4	0.793478	0.908046	Türkiye'de teknoloji alanında uluslararası dü
11	Temp_1.3	Makine öğrenmesi modelleri	18.2	0.692308	0.895349	Makine öğrenmesi modelleri) 6\n6 13. SINIF 1
12	TopP_0.8	Yapay zeka gelecekte	19.0	0.663158	0.866667	Yapay zeka gelecekte ortaya çıkabilecek en ön
13	TopP_0.8	Bu çalışmada önerilen yöntem	20.0	0.590000	0.800000	Bu çalışmada önerilen yöntem ise, kullanılan
14	TopP_0.8	Türkiye'de teknoloji alanında	18.0	0.700000	0.894118	Türkiye'de teknoloji alanında faaliyet göste
15	TopP_0.8	Makine öğrenmesi modelleri	18.8	0.542553	0.719101	Makine öğrenmesi modelleri ile çok daha kola
16	TopP_0.95	Yapay zeka gelecekte	18.8	0.691489	0.898876	Yapay zeka gelecekte ne kadar çok yeni olurs

Şekil 4.8. Örnekleme Stratejilerine Göre Üretilen Örnek Metin Çıktılarının Nitel Karşılaştırması

Sonuç olarak; kontrollü metinler için orta düzey temperature ve dar çekirdek (TopP_0.8) değerleri uygun görünürken, yaratıcı senaryolarda daha yüksek sampling değerleri tercih edilebilir. Bu çalışma, Türkçe GPT tabanlı üretimde ideal parametre setinin belirlenmesi için metodolojik bir temel sunmaktadır.

5.Sonuç ve Gelecekteki Çalışmalar

5.1.SONUÇ

Bu çalışmada, GPT-2 tabanlı bir Türkçe dil modeli kullanılarak farklı sampling stratejilerinin metin üretimi üzerindeki etkileri kapsamlı biçimde incelenmiştir. Temperature sampling ve nucleus (top-p) sampling gibi yaygın çıkarım yöntemleri, hem otomatik değerlendirme metrikleri hem de insan değerlendirmesi aracılığıyla karşılaştırılmıştır. Elde edilen sonuçlar, sampling parametrelerinin yalnızca sözcüksel çeşitliliği değil, aynı zamanda insan tarafından algılanan metin kalitesini de doğrudan etkilediğini ortaya koymaktadır.

Otomatik değerlendirme sonuçları, daha yüksek temperature ve top-p değerlerinin Distinct-1 ve Distinct-2 skorlarını artırarak metin çeşitliliğini belirgin biçimde yükselttiğini göstermiştir. Ancak bu artan çeşitlilik, insan değerlendirmesinde her zaman daha yüksek kalite algısıyla örtüşmemiştir. Özellikle yüksek temperature değerlerinde, üretilen metinlerin tutarlılık ve anlamsallık açısından daha değişken sonuçlar verdiği gözlemlenmiştir.

İnsan değerlendirmesi bulguları, orta düzey sampling ayarlarının (örneğin Temperature = 1.0 veya top-p = 0.8) Türkçe metin üretimi için daha dengeli bir performans sunduğunu göstermektedir. Bu ayarlar, yeterli çeşitlilik sağlarken metnin akıcılığını ve anlamsal bütünlüğünü büyük ölçüde koruyabilmiştir. Bu sonuç, Türkçe gibi morfolojik açıdan zengin dillerde sampling stratejilerinin dikkatli bir şekilde ayarlanması gerektiğini ortaya koymaktadır.

Genel olarak bu çalışma, Türkçe GPT tabanlı metin üretiminde sampling stratejilerinin etkisini sistematik ve çok boyutlu bir biçimde ele alarak literatürdeki önemli bir boşluğu doldurmaktadır. Otomatik metrikler ile insan algısı arasındaki farkların açıkça gösterilmesi, gelecekte yapılacak metin üretimi çalışmalarına metodolojik bir rehber sunmaktadır.

5.2.Gelecekteki Çalışmalar

Bu çalışmanın bazı sınırlılıkları bulunmaktadır. Öncelikle, deneyler yalnızca tek bir önceden eğitilmiş Türkçe GPT-2 modeli üzerinde gerçekleştirilmiştir. Farklı mimariler veya daha büyük ölçekli modeller kullanılarak yapılacak karşılaştırmalar, elde edilen bulguların genellenebilirliğini artırabilir.

İkinci olarak, metin üretimi sınırlı sayıda prompt ve kısa çıktı uzunlukları ile değerlendirilmiştir. Daha uzun metinler ve farklı türlerde (örneğin diyalog, hikâye veya teknik metin) promptlar kullanılarak yapılacak analizler, sampling stratejilerinin etkisini daha ayrıntılı biçimde ortaya koyabilir.

Ayrıca, insan değerlendirmesi sınırlı sayıda örnek üzerinden gerçekleştirilmiştir. Daha fazla değerlendirici ve daha geniş bir örneklem ile yapılacak çalışmalar, insan algısına ilişkin sonuçların istatistiksel gücünü artıracaktır. Gelecek çalışmalarda, otomatik metrikler ile insan değerlendirmesi arasındaki ilişkiyi modelleyen korelasyon analizlerinin derinleştirilmesi de önemli bir araştırma yönü olarak değerlendirilmektedir.

Bu sınırlılıklara rağmen, sunulan deneysel analizler Türkçe metin üretiminde sampling parametrelerinin rolüne dair önemli içgörüler sunmakta ve ileride yapılacak çalışmalar için sağlam bir başlangıç noktası oluşturmaktadır.

KAYNAKÇA

[1] Fan, A., Lewis, M., & Dauphin, Y. (2018). Hierarchical neural story generation. Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), 889–898.

[2] Holtzman, A., Buys, J., Du, L., Forbes, M., & Choi, Y. (2019). The curious case of neural text degeneration. arXiv preprint arXiv:1904.09751.

[3] Liu, C. W., Lowe, R., Serban, I. V., Noseworthy, J., Charlin, L., & Pineau, J. (2016). How NOT to evaluate your dialogue system: An empirical study of unsupervised evaluation metrics for dialogue response generation. Proceedings of the 2016 Conference on Empirical Methods in Natural Language Processing, 2122–2132.

[4] Radford, A., Wu, J., Child, R., Luan, D., Amodei, D., & Sutskever, I. (2019). Language models are unsupervised multitask learners. OpenAI Blog.

[5] See, A., Roller, S., Kiela, D., & Jason, W. (2019). What makes a good conversation? How controllable attributes affect human judgments. Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers), 1702–1723.

[6] Yavuz, S., et al. (2022). Morfolojik zengin dillerde büyük dil modellerinin performans analizi: Türkçe örneği. Doğal Dil İşleme Konferansı Bildirileri.

[7] Zhu, Y., Lan, S., Zhou, Z., Zhao, L., & Zhang, W. (2018). Texygen: A benchmarking platform for text generation models. The 41st International ACM SIGIR Conference on Research & Development in Information Retrieval, 1097–1100.